

Trabajo de Fin de Grado
Grado en Física

MACHINE LEARNING:
Métodos de ensamble aplicados a la
estimación de la temperatura crítica en
materiales superconductores

Marcos Barba Ballarín


Director: Ricardo López Ruiz

Facultad de Ciencias
Universidad de Zaragoza

19 de mayo de 2026



Machine Learning

- ▶ Tipos de aprendizaje
 - ▶ Aprendizaje supervisado
 - ▶ Aprendizaje no supervisado
- ▶ División del conjunto de datos
- ▶ Hiperparámetros
- ▶ Evaluación del modelo
 - ▶ *Cross-Validation* (Validación Cruzada)



Árboles de decisión

- ▶ División del espacio de predictores.
- ▶ Determinar una predicción para cada región.



Árboles de decisión

Entrenamiento del árbol

► *Recursive binary splitting*

Q_m conjunto de observaciones en el nodo m .

Para cada cada posible división $\theta = (j, t_m)$:

$$Q_m^{left}(\theta) = \{(X_i, Y_i) | x_{ij} \leq t_m\}$$

$$Q_m^{right}(\theta) = \{(X_i, Y_i) | x_{ij} > t_m\}$$

$$\mathcal{I}(Q_m, \theta) = \frac{|Q_m^{left}|}{|Q_m|} \mathcal{L}(Q_m^{left}(\theta)) + \frac{|Q_m^{right}|}{|Q_m|} \mathcal{L}(Q_m^{right}(\theta))$$

$\mathcal{L}()$ función de impureza.

Árboles de decisión

Árboles de regresión

Error cuadrático medio (MSE):

$$\mathcal{L}(Q_m) = \frac{1}{|Q_m|} \sum_{y \in Q_m} (y - \bar{y}_m)^2$$

$$\bar{y}_m = \frac{1}{|Q_m|} \sum_{y \in Q_m} y$$

Error Medio absoluto (MAE):

$$\mathcal{L}(Q_m) = \frac{1}{|Q_m|} \sum_{y \in Q_m} |y - \text{mediana}(y)_m|$$

$$\text{mediana}(y)_m = \text{mediana}(y)$$

Árboles de decisión

Evitar el *overfitting*

Early Stopping:

- ▶ n^o mínimo para división.
- ▶ n^o mínimo para nodo terminal.
- ▶ Profundidad máxima del árbol.
- ▶ n^o máximo de nodos terminales.
- ▶ Reducción mínima del error.

Tree Pruning:

- ▶ Generar árboles grandes.
- ▶ Buscar subárbol óptimo.
- ▶ *Minimal Cost-complexity pruning.*


Métodos de ensamble

- ▶ Acoplamiento de modelos.
- ▶ Modelo débil: algo mejor que el azar.
- ▶ *Stacking, Bagging, Boosting.*

Métodos de ensamble

Stacking


- ▶ Modelos base distintos.
- ▶ *Out-of-fold predictions* para entrenar *meta-model*.
- ▶ *Meta-model* computa la predicción final.



Métodos de ensemble

Bagging

- ▶ Modelos base iguales.
- ▶ Entrenados sobre subconjuntos del conjunto de entrenamiento, obtenidos mediante remuestreo con remplazo (*bootstrap*).
- ▶ Predicciones finales obtenidas por agregación (*aggregating*).



Métodos de ensamble

Bagging


Random Forest

- ▶ Reducción de la correlación entre los árboles que componen el bosque.
- ▶ Para las divisiones de cada nodo, se tendrá en cuenta sólo un subconjunto aleatorio de características.
- ▶ Agregación final generaliza mejor a nuevos datos.

Métodos de ensemble

Boosting

- ▶ Modelos base iguales.
- ▶ Entrenamiento secuencial y aditivo.
- ▶ Cada nuevo modelo base se entrena prestando mayor atención a las observaciones mal predichas por sus predecesores.



Métodos de ensamble

Boosting

- ▶ *AdaBoost*: asignación de pesos a las muestras.
- ▶ *Gradient Boosting*: los modelos base se entrenan para predecir el pseudoresiduo (gradiente negativo de la función pérdida).
- ▶ *XGBoost (Xtreme Gradient Boosting)*: extiende el concepto de descenso del gradiente a la construcción del árbol (*XGBTree*).

Estimación de la temperatura crítica

Introducción

- ▶ Superconductores: materiales cuya resistividad eléctrica desaparece cuando se enfrían por debajo de su **temperatura crítica** (T_c).
- ▶ Superconductores de alta temperatura.
- ▶ La predicción de la temperatura crítica es un problema abierto.
- ▶ Métodos de ensamble para predecir la temperatura crítica a partir de las propiedades físicas y químicas de los materiales.

Estimación de la temperatura crítica

Conjuntos de datos y descriptores

- ▶ Base de datos de materiales superconductores del *Instituto Nacional para la Ciencia de Materiales (NIMS) de Japón*. 21.263 muestras de superconductores.
- ▶ Propiedades referidas a los elementos que componen el material:
 - ▶ **Número de elementos**
 - ▶ **Masa atómica** [UMA]
 - ▶ **Primera energía de ionización** (*fie*) [kJ/mol]
 - ▶ **Radio atómico** [pm]
 - ▶ **Densidad** [kg/m^3]
 - ▶ **Afinidad electrónica** [kJ/mol]
 - ▶ **Calor de fusión** [kJ/mol]
 - ▶ **Conductividad térmica** [$\text{W}/(\text{m} \cdot \text{K})$]
 - ▶ **Valencia**

Estimación de la temperatura crítica

Conjuntos de datos y descriptores

- ▶ Familias de descriptores estadísticos referentes a los compuestos:
 - ▶ **Media aritmética** (mean_*)
 - ▶ **Media ponderada** (wtd_mean_*)
 - ▶ **Media geométrica** (gmean_*)
 - ▶ **Media geométrica ponderada** (wtd_gmean_*)
 - ▶ **Entropía** (entropy_*)
 - ▶ **Entropía ponderada** (wtd_entropy_*)
 - ▶ **Rango** (range_*)
 - ▶ **Rango ponderado** (wtd_range_*)
 - ▶ **Desviación estandar** (std_*)
 - ▶ **Desviación estandar ponderada** (wtd_std_*)

Estimación de la temperatura crítica

Conjunto de datos y descriptores

Familias de descriptores para el YBCO:

Propiedades mean

Propiedad	Valor
mean_atomic_mass	68.24625
mean_fie	886.18
mean_atomic_radius	147.4
mean_Density	3389.3286
mean_ElectronAffinity	131.89
mean_FusionHeat	7.1844
mean_ThermalConductivity	87.007096
mean_Valence	2.8

Propiedades range

Propiedad	Valor
range_atomic_mass	121.3276
range_fie	810.6
range_atomic_radius	205.0
range_Density	8958.571
range_ElectronAffinity	335.05
range_FusionHeat	12.878
range_ThermalConductivity	399.9911
range_Valence	3.0

Temperatura Crítica

Propiedad	Valor
critical_temp	72.0

Estimación de la temperatura crítica

Modelado

- ▶ *Random Forest*
 - ▶ *XGBoost*
 - ▶ *Árbol de decisión simple*
-
- ▶ Función de pérdida: Error cuadrático medio (MSE)

Estimación de la temperatura crítica

Modelado

Métricas de evaluación

$$\blacktriangleright RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

$$\blacktriangleright R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2}$$

$$\blacktriangleright MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \rightarrow sMAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{(\hat{y}_i + y_i)/2} \right|$$

Evaluación previa

- ▶ Evaluación del rendimiento mediante *cross-validation*.

	$RMSE (K)$	R^2	$sMAPE (\%)$
Random Forest	9.718	0.920	26.373
XGBoost	9.787	0.919	32.424
Decision Tree	12.403	0.869	29.186

Estimación de la temperatura crítica

Resultados

- ▶ Entrenamiento sobre el subconjunto de entrenamiento.
- ▶ Validación sobre el subconjunto de test.



	$RMSE (K)$	R^2	$sMAPE (\%)$
Random Forest	9.042	0.929	25.187
XGBoost	8.973	0.925	32.975

- ▶ Tuneo de hiperparámetros.

	$RMSE (K)$	R^2	$sMAPE (\%)$
Random Forest	8.979	0.930	25.740
XGBoost	8.668	0.935	27.606



Estimación de la temperatura crítica

Resultados - Comparación entre los valores reales y predichos



Estimación de la temperatura crítica



Resultados - Importancia de las variables



Estimación de la temperatura crítica

Conclusiones

	$RMSE (K)$	R^2	$sMAPE (\%)$
Random Forest	8.979	0.930	25.740
XGBoost	8.668	0.935	27.606



Estimación de la temperatura crítica

Conclusiones

- ▶ Capturan las tendencias globales.
- ▶ Limitados para predicciones individuales.
- ▶ Interpretabilidad: análisis de importancia de variables.
- ▶ Equilibrio entre precisión y explicabilidad.